

Documentação Técnica de Validação

Sistema CREDERE — Scoring de Crédito Explicável
Documento elaborado pelo autor e criador do sistema
Validação sobre o dataset público *Loan Prediction*

Natureza do documento: documentação técnica de validação de um protótipo, elaborada pelo próprio autor do sistema. NÃO constitui uma auditoria independente nem um parecer de auditor certificado. Os resultados baseiam-se num dataset público e destinam-se a demonstração técnica; ver a secção de Limitações.

1. Sumário Executivo

Este relatório documenta a análise do sistema CREDERE aplicado a um conjunto de 614 candidaturas de crédito reais. O sistema foi treinado exclusivamente com 8 variáveis financeiras legítimas, tendo sido deliberadamente excluídas as variáveis sensíveis (género, estado civil, dependentes, educação) para prevenir discriminação.

Principais conclusões

- O melhor modelo (**logística**) atingiu uma AUC de **80.5%** na previsão da decisão de aprovação.
- A variável **Credit_History** domina largamente a decisão, concentrando a maior parte do poder preditivo.
- Foi detetado **viés histórico** no dataset nas variáveis: Married, Dependents.
- Ao excluir as variáveis protegidas, o modelo **reduziu** o viés: a disparidade em 'Married' deixou de ser adversa nas predições.

2. Qualidade dos Dados

O dataset contém 614 registos. A variável-alvo representa a taxa de aprovação histórica de **68.7%**. Os valores em falta foram tratados por imputação, de forma documentada:

- LoanAmount: 22 valores em falta imputados com a mediana (128).
- Loan_Amount_Term: 14 valores em falta imputados com a mediana (360).
- Credit_History: 50 valores em falta imputados com a mediana (1).


3. Desempenho dos Modelos

Foram treinados e comparados três modelos sobre os mesmos dados. As métricas são padrão da indústria: AUC e Gini medem a capacidade de discriminação; KS mede a separação máxima entre distribuições; Brier mede a calibração (menor é melhor).

Modelo	AUC	Gini	KS	Brier
logistica	0.805	0.610	0.495	0.136
xgboost	0.762	0.524	0.438	0.156
ensemble_hibrido	0.784	0.568	0.466	0.141

Nota: num dataset em que uma única variável domina e as relações são sobretudo lineares, é esperado e legítimo que um modelo simples (regressão logística) iguale ou supere modelos mais complexos. Este é um sinal de maturidade analítica, não uma deficiência.

4. Importância das Variáveis



A variável **Credit_History** concentra a maior parte do poder preditivo. Isto significa, na prática, que a decisão do sistema depende sobretudo do historial de crédito do candidato — um critério legítimo e transparente.

5. Auditoria de Equidade (Fairness)

A auditoria aplica a regra dos quatro quintos (4/5) da EEOC: se a taxa de aprovação de um grupo for inferior a 80% da do grupo mais favorecido, há indício de impacto adverso. Analisámos o viés no próprio histórico (o que o banco fez) e nas predições do modelo (o que o sistema faria).

5.1. Viés histórico no dataset

Variável	Rácio 4/5	Impacto adverso
Gender	0.89	não
Married	0.63	SIM
Dependents	0.80	SIM
Education	0.86	não
Self_Employed	0.95	não

5.2. Viés nas predições do modelo

O modelo não usa as variáveis protegidas. Esta análise verifica se, ainda assim, produz disparidade (por correlação indireta).

Variável	Rácio 4/5	Impacto adverso
Gender	0.81	não
Married	0.84	não
Dependents	0.77	SIM
Education	0.92	não
Self_Employed	0.90	não

6. Testes de Segurança, Robustez e Qualidade

Foi executada uma bateria de 28 testes automatizados de validação, cobrindo robustez a dados maliciosos, integridade do registo, privacidade, fuga de dados no treino, deteção de alucinações, enviesamento e precisão. Resultado global: **24 aprovados**, 4 com atenção, 0 falhas.

Robustez e Integridade

Teste	Resultado	Detalhe
Resistência a entradas malformadas	Aprovado	5/5 entradas maliciosas ou impossíveis (valores negativos, extremos, injeção textual tipo SQL, campos em falta) foram tratadas sem falha e sem aprovar dados inválidos.
Imunidade a injeção (SQL/código)	Aprovado	O motor de decisão não interpreta texto como comando (não há SQL dinâmico, eval ou template execution). Cadeias maliciosas em campos de texto são tratadas como dados inertes.
Deteção de adulteração do registo	Aprovado	O registo de auditoria (hash chain SHA-256) estava íntegro antes da manipulação e detetou imediatamente a adulteração de um registo passado — qualquer alteração quebra a cadeia de hashes.
Teste adversário (red team)	Aprovado	O agente adversário executou 8 ataques (dados adulterados, zonas cinzentas, combinações raras). Foram encontradas 0 vulnerabilidades. O red team foi validado contra um sistema partido, onde deteta falhas reais — pelo que o resultado nulo significa resistência efetiva.

Privacidade e Minimização de Dados

Teste	Resultado	Detalhe
Minimização na memória de casos	Aprovado	O texto indexado na memória de casos descreve o perfil por faixas de risco (ex: 'rendimento alto'), não valores exatos. Um rendimento de 3517 não aparece no índice — protege a privacidade e cumpre a minimização de dados do RGPD.
Explicação sem dados excedentes	Aprovado	A explicação em linguagem natural contém apenas o que o titular tem direito a saber (score e fatores da decisão), sem expor dados de terceiros nem informação além da necessária.

Fuga de Dados no Treino (Data Leakage)

Teste	Resultado	Detalhe
Correlação feature-alvo	Aprovado	A feature mais correlacionada com o alvo é 'Credit_History' (correlação 0.54) — nenhuma feature espreita o target.
Separação treino/teste	Aprovado	A avaliação é feita numa partição de teste independente (30%), com estratificação, gerada antes do treino. O modelo nunca vê os dados de teste durante o ajuste — não há contaminação.

Deteção de Alucinações

Teste	Resultado	Detalhe
Deteção de factos falsos em explicações	Aprovado	A explicação correta foi validada e 2/2 explicações corrompidas (score falso, contribuição inventada) foram detetadas e rejeitadas. Como as explicações são geradas por templating determinístico a partir dos dados, não há alucinação na origem; o verificador é a salvaguarda adicional.

Precisão e Acerto

Teste	Resultado	Detalhe
AUC-ROC (métrica principal)	Aprovado	AUC-ROC de 0.784 — a métrica de referência para scoring de crédito, mede a capacidade de ordenar bons e maus independentemente do limiar (0.5 = aleatório, 1.0 = perfeito; critério: ≥ 0.70). PREVINE: avaliar o modelo só por accuracy, que engana quando as classes são desequilibradas.
Acerto global (accuracy)	Aprovado	Acerto de 82.2% na reprodução da decisão histórica, sobre 185 casos.
Precisão e recall	Aprovado	Precisão 80.1% (das aprovações previstas, quantas corretas) e recall 98.4% (dos aprovados reais, quantos identificados). F1 = 88.3%.
Matriz de confusão	Aprovado	Verdadeiros positivos (aprovados corretos): 125 (68%); falsos positivos (aprovados indevidos): 31 (17%); verdadeiros negativos (recusados corretos): 27 (15%); falsos negativos (recusados indevidos): 2 (1%). O erro mais custoso num sistema de crédito é o falso positivo (aprovar quem não devia).

Enviesamento (Fairness)

Teste	Resultado	Detalhe
Disparate impact nas predições	Atenção	Regra dos 4/5 aplicada às predições do modelo — impacto adverso residual em: Dependents (por correlação indireta, apesar de a variável não ser usada). Rácios mais baixos: Dependents 0.77, Gender 0.81, Married 0.84. O modelo não usa variáveis protegidas; qualquer disparidade residual vem de correlação com variáveis legítimas e é monitorizada.

A. Calibração e Estabilidade

Teste	Resultado	Detalhe
A.1 Diagrama de calibração (reliability)	Aprovado	As probabilidades previstas foram divididas em 10 grupos e comparadas com a frequência real de aprovação. A inclinação da curva de calibração é 1.13 (ideal = 1.00; critério: entre 0.85 e 1.15). Dentro do critério. PREVINE: decisões baseadas em probabilidades enganadoras (ex: dizer '90% de risco' quando o risco real é 70%).
A.2 Pós-calibração (Platt / Isotonic)	Atenção	Aplicou-se Platt scaling (Brier 0.141) e isotonic regression (Brier 0.126) ao modelo. O melhor Brier pós-calibração é 0.126 vs 0.136 original (variação +7.0%; critério: -10% ou < 0.12). O modelo já está bem calibrado — pouca margem de melhoria, o que é positivo. RESOLVE: probabilidades mal calibradas que distorceriam decisões de corte e provisionamento.
A.3 Estabilidade entre partições (PSI)	Aprovado	O PSI foi calculado entre treino e teste para todas as variáveis. O valor mais alto é 0.083 ('ApplicantIncome'; critério: < 0.1 ok, 0.1-0.2 alerta, > 0.2 falha) — estabilidade elevada. PREVINE: treinar e avaliar em populações diferentes, que daria métricas otimistas e falsas. Serve de baseline para deteção de drift em dados futuros.

B. Explicabilidade e Transparência

Teste	Resultado	Detalhe
-------	-----------	---------

B.1 Explicação local factual	Aprovado	Geraram-se explicações para 5 casos. 5/5 passaram todos os critérios: factos corretos (score e contribuições batem com os dados), consistência aritmética, e ausência de variáveis protegidas. GARANTE: o direito a explicação (RGPD art. 22) com justificações verdadeiras e não-discriminatórias.
B.2 Estabilidade da explicação	Aprovado	Aplicou-se uma perturbação de +5% ao rendimento em 5 casos e comparou-se a ordem dos fatores. 5/5 mantiveram-se estáveis (desvio ≤ 1 posição). NOTA HONESTA: como as explicações derivam de escalões discretos (não de SHAP contínuo), a estabilidade é elevada por construção — este teste é menos exigente do que num modelo puramente contínuo. PREVINE: explicações erráticas que minariam a confiança do titular.

C. Segurança Avançada (Adversarial)

Teste	Resultado	Detalhe
C.1 Ataque de fronteira (gaming)	Aprovado	Partindo de 28 casos reprovados, aplicaram-se alterações plausíveis (≤ 1 desvio-padrão) ao rendimento e montante. 0 (0%) mudaram para aprovado. Abaixo do limiar de risco — o sistema não é facilmente manipulável. PREVINE: candidatos manipularem inputs (ex: inflacionar ligeiramente o rendimento) para forçar aprovação.
C.2 Inversão de modelo	Atenção	Tentou reconstruir-se o rendimento a partir do score. A gama de rendimentos compatíveis com o mesmo score cobre em média 34% da amplitude total (critério: $> 50\%$ = não há reconstrução precisa). O score é demasiado informativo sobre o rendimento. NOTA: relevante sobretudo para exposição futura via API pública; em modo biblioteca é um stress test interno. PREVINE: fuga de dados sensíveis por consulta repetida de scores.
C.3 Robustez a combinações extremas	Aprovado	Geraram-se 20 combinações extremas mas possíveis (rendimento alto sem crédito, baixo com pedido elevado, valores contraditórios). 20/20 foram tratadas sem erro; 0 registos impossíveis foram aprovados (critério: 0). PREVINE: falhas e aprovações indevidas perante combinações raras que o treino não cobriu.

D. Fairness e Viés Estrutural

Teste	Resultado	Detalhe
D.1 Correlação indireta com protegidas	Aprovado	Mediu-se a correlação entre cada variável legítima e cada variável protegida. A mais alta é 0.17 entre 'LoanAmount' e 'Education' (critério: ≤ 0.6). Nenhuma variável legítima é um proxy forte de uma protegida. PREVINE: discriminação indireta, em que uma variável 'neutra' carrega informação de uma característica protegida.
D.2 Viés interseccional	Aprovado	Analisaram-se 4 subgrupos combinados (género x estado civil) com ≥ 30 casos. Taxas de aprovação previstas: Female+No 82%, Male+No 85%, Male+Yes 86%, Female+Yes 87%. Rácio 4/5 mínimo entre subgrupos: 0.95 (critério: ≥ 0.8). Sem disparidade interseccional relevante. DETETA: discriminação que só aparece na interseção de atributos (ex: mulheres com dependentes), invisível na análise isolada.

E. Operacionalidade e Deriva

Teste	Resultado	Detalhe
-------	-----------	---------

E.1 Deriva de conceito (concept drift)	Aprovado	Simulou-se uma mudança de mercado reduzindo em 30% o peso do histórico de crédito. A AUC passou de 0.805 para 0.805 (queda de 0.0 p.p.; critério: ≤ 5 p.p.). O modelo é robusto a esta deriva. PREVINE: degradação silenciosa quando a relação entre variáveis e resultado muda ao longo do tempo.
E.2 Desempenho com partição temporal	Atenção	Comparou-se a AUC com partição aleatória (0.805) vs partição sequencial pela ordem do ficheiro (0.729); diferença 7.6 p.p. (critério: ≤ 3 p.p.). NOTA HONESTA IMPORTANTE: o dataset NÃO tem coluna de data. A ordem do ficheiro não tem significado temporal real, pelo que este teste é um PLACEHOLDER metodológico para quando existirem dados datados — não mede sazonalidade verdadeira. PREPARA: a deteção de sensibilidade temporal em dados reais futuros. RECOMENDAÇÃO: em produção, substituir pela ordenação por carimbo temporal real e reavaliar a sensibilidade à sazonalidade.

F. Conformidade Regulatória (AI Act)

Teste	Resultado	Detalhe
F.1 Checklist de transparência (AI Act art. 13)	Aprovado	Auditou-se a documentação contra os elementos exigidos pelo AI Act para sistemas de alto risco: 7/7 presentes. Todos os elementos obrigatórios estão cobertos: descrição, dados, métricas globais e por subgrupo, limitações, supervisão humana e mitigação de viés. GARANTE: conformidade documental com os requisitos de transparência para sistemas de crédito de alto risco.
F.2 Supervisão humana (human-in-the-loop)	Aprovado	Identificaram-se 1 casos de baixa confiança (probabilidade entre 0.45 e 0.55). 1/1 foram corretamente sinalizados para revisão humana, cada um com um resumo executivo para o analista — sem automatizar a decisão final. DEMONSTRA: a supervisão humana efetiva exigida pelo AI Act para decisões de alto risco em casos incertos.

Nota sobre segurança: o sistema é uma biblioteca de decisão, sem servidor nem interface de rede exposta. Por isso, os vetores de ataque relevantes são dados maliciosos à entrada e adulteração de registos — que foram testados — e não ataques a servidor (que só seriam aplicáveis com uma API, camada ainda não implementada).

7. Limitações (Declaração do Autor)

- **O alvo não é incumprimento.** APROVAÇÃO HISTÓRICA pelo banco (Loan_Status). NÃO é incumprimento real — o dataset não contém informação de default. Um modelo treinado nisto aprende a replicar a decisão passada do banco, incluindo os seus eventuais enviesamentos.
- **Dataset de demonstração.** Com 614 registos e origem pública, os resultados servem para validar a arquitetura, não para produção real.
- **Sem calibração a incumprimento real.** Um sistema de produção exigiria dados longitudinais de default, validação jurídica (DPO) e supervisão humana contínua, conforme o AI Act.
- **Viés residual.** Excluir variáveis protegidas reduz mas não elimina o viés, que pode persistir por correlação com variáveis legítimas — daí a monitorização contínua.

8. Metodologia e Reprodutibilidade

Todos os resultados foram gerados por código testado (mais de 200 testes automatizados). O pipeline (carregamento, imputação, treino, avaliação, auditoria) é determinístico e reprodutível. Os modelos foram avaliados em partição de teste independente (30%), com estratificação. As métricas de equidade seguem a regra dos 4/5 da EEOC.