

Documento de Sistema

Sistema CREDERE — Scoring de Crédito Explicável
Árvore de decisão · Relatório de testes · Checklist AI Act
Documento elaborado pelo autor e criador do sistema

Natureza do documento: documentação técnica elaborada pelo próprio autor do sistema. NÃO constitui auditoria independente, parecer jurídico, nem avaliação de conformidade formal ao abrigo do AI Act. O checklist da secção 3 é uma autoavaliação técnica dos requisitos cobertos pelo protótipo.


Nota importante sobre o alvo do modelo: este sistema prevê a **decisão histórica de aprovação** do banco, NÃO o risco de incumprimento (default). O dataset de demonstração não contém informação de default. Para produção, seria necessário retreinar com dados reais de incumprimento.

Conteúdo

- 1. Árvore de Decisão do Sistema — o caminho de cada candidatura
- 2. Relatório Completo dos Testes de Validação — 26 baterias
- 3. Checklist AI Act — autoavaliação técnica de cobertura

1. Árvore de Decisão do Sistema

O diagrama mostra o caminho real que cada candidatura percorre. O fluxo é determinístico: a mesma candidatura percorre sempre o mesmo caminho, o que garante decisões reproduzíveis e auditáveis. Os desvios (a vermelho e âmbar) mostram as ramificações de proteção: bloqueios, vetos e escalonamento humano.



1.1. Explicação de cada etapa

1. Guardrail de Entrada

O que faz: Valida a plausibilidade dos dados (limites físicos, campos obrigatórios) e deteta anomalias como rendimento inflacionado ou incoerências entre campos.

Porque existe: Impede que dados corrompidos, impossíveis ou manipulados cheguem sequer ao motor de decisão. É a primeira linha de defesa.

2. Scoring / MoE

O que faz: Atribui pontos por fator através de um scorecard explicável, com especialização por segmento (particular, PME, corporate) e ajuste por cenário macroeconómico. Produz o score e os reason codes.

Porque existe: Garante que cada decisão é explicável por construção: cada ponto tem origem num fator identificável — a base do direito a explicação.

3. Compliance (neuro-simbólico)

O que faz: Submete a decisão estatística a regras determinísticas duras (limite de taxa de esforço, proibição de características protegidas, justificação obrigatória). Uma regra dura violada VETA a decisão.

Porque existe: Quando o modelo e a lei entram em conflito, a lei ganha sempre. É o que torna o sistema defensável perante regulação de alto risco.

4. Guardrail de Saída

O que faz: Cruza o cliente com listas de exclusão (sanções, fraude conhecida) e verifica invariantes que nenhuma decisão pode violar (ex: recusa sem justificação).

Porque existe: Garante que mesmo uma decisão meritória não sai se o cliente não puder ser servido, e que nenhuma decisão malformada é libertada.

5. Human-in-the-Loop

O que faz: Identifica decisões incertas (revisão manual, veto, sinalização de guardrail) e escala-as a um gestor humano com um resumo executivo. O humano pode aceitar, modificar ou vetar.

Porque existe: A supervisão humana efetiva exigida pelo AI Act: o sistema nunca decide sozinho os casos em que ele próprio reconhece incerteza.

6. Ledger de Auditoria

O que faz: Regista cada decisão (resultado, versão do sistema, alertas) numa cadeia de hashes SHA-256 — cada registo referencia o anterior.

Porque existe: Qualquer adulteração de um registo passado quebra a cadeia e é detetada. Auditabilidade criptográfica sem a complexidade de uma blockchain.

Explicação (transversal)

O que faz: Cada decisão gera uma justificação em português por templating determinístico a partir dos reason codes, verificada pelo detetor de alucinações.

Porque existe: O titular recebe uma explicação exata ao número — nunca gerada livremente por um modelo de linguagem, eliminando o risco de alucinação numa comunicação legalmente sensível.

2. Relatório Completo dos Testes de Validação

Foram executadas 28 baterias de teste automatizadas sobre o sistema e o dataset real. Resultado global: **24 aprovadas**, 4 com atenção, 0 falhadas. Cada teste descreve o que valida, como avalia (critério), o resultado obtido e o que resolve ou previne.

Robustez e Integridade

Teste	Resultado	Explicação, avaliação e propósito
Resistência a entradas malformadas	Aprovado	5/5 entradas maliciosas ou impossíveis (valores negativos, extremos, injeção textual tipo SQL, campos em falta) foram tratadas sem falha e sem aprovar dados inválidos.
Imunidade a injeção (SQL/código)	Aprovado	O motor de decisão não interpreta texto como comando (não há SQL dinâmico, eval ou template execution). Cadeias maliciosas em campos de texto são tratadas como dados inertes.
Deteção de adulteração do registo	Aprovado	O registo de auditoria (hash chain SHA-256) estava íntegro antes da manipulação e detetou imediatamente a adulteração de um registo passado — qualquer alteração quebra a cadeia de hashes.
Teste adversário (red team)	Aprovado	O agente adversário executou 8 ataques (dados adulterados, zonas cinzentas, combinações raras). Foram encontradas 0 vulnerabilidades. O red team foi validado contra um sistema partido, onde deteta falhas reais — pelo que o resultado nulo significa resistência efetiva.

Privacidade e Minimização de Dados

Teste	Resultado	Explicação, avaliação e propósito
Minimização na memória de casos	Aprovado	O texto indexado na memória de casos descreve o perfil por faixas de risco (ex: 'rendimento alto'), não valores exatos. Um rendimento de 3517 não aparece no índice — protege a privacidade e cumpre a minimização de dados do RGPD.
Explicação sem dados excedentes	Aprovado	A explicação em linguagem natural contém apenas o que o titular tem direito a saber (score e fatores da decisão), sem expor dados de terceiros nem informação além da necessária.

Fuga de Dados no Treino (Data Leakage)

Teste	Resultado	Explicação, avaliação e propósito
Correlação feature-alvo	Aprovado	A feature mais correlacionada com o alvo é 'Credit_History' (correlação 0.54) — nenhuma feature espreita o target.
Separação treino/teste	Aprovado	A avaliação é feita numa partição de teste independente (30%), com estratificação, gerada antes do treino. O modelo nunca vê os dados de teste durante o ajuste — não há contaminação.

Deteção de Alucinações

Teste	Resultado	Explicação, avaliação e propósito
Deteção de factos falsos em explicações	Aprovado	A explicação correta foi validada e 2/2 explicações corrompidas (score falso, contribuição inventada) foram detetadas e rejeitadas. Como as explicações são geradas por templating determinístico a partir dos dados, não há alucinação na origem; o verificador é a salvaguarda adicional.

Precisão e Acerto

Teste	Resultado	Explicação, avaliação e propósito
AUC-ROC (métrica principal)	Aprovado	AUC-ROC de 0.784 — a métrica de referência para scoring de crédito, mede a capacidade de ordenar bons e maus independentemente do limiar (0.5 = aleatório, 1.0 = perfeito; critério: ≥ 0.70). PREVINE: avaliar o modelo só por accuracy, que engana quando as classes são desequilibradas.
Acerto global (accuracy)	Aprovado	Acerto de 82.2% na reprodução da decisão histórica, sobre 185 casos.
Precisão e recall	Aprovado	Precisão 80.1% (das aprovações previstas, quantas corretas) e recall 98.4% (dos aprovados reais, quantos identificados). F1 = 88.3%.
Matriz de confusão	Aprovado	Verdadeiros positivos (aprovados corretos): 125 (68%); falsos positivos (aprovados indevidos): 31 (17%); verdadeiros negativos (recusados corretos): 27 (15%); falsos negativos (recusados indevidos): 2 (1%). O erro mais custoso num sistema de crédito é o falso positivo (aprovar quem não devia).

Enviesamento (Fairness)

Teste	Resultado	Explicação, avaliação e propósito
Disparate impact nas predições	Atenção	Regra dos 4/5 aplicada às predições do modelo — impacto adverso residual em: Dependents (por correlação indireta, apesar de a variável não ser usada). Rácios mais baixos: Dependents 0.77, Gender 0.81, Married 0.84. O modelo não usa variáveis protegidas; qualquer disparidade residual vem de correlação com variáveis legítimas e é monitorizada.

A. Calibração e Estabilidade

Teste	Resultado	Explicação, avaliação e propósito
A.1 Diagrama de calibração (reliability)	Aprovado	As probabilidades previstas foram divididas em 10 grupos e comparadas com a frequência real de aprovação. A inclinação da curva de calibração é 1.13 (ideal = 1.00; critério: entre 0.85 e 1.15). Dentro do critério. PREVINE: decisões baseadas em probabilidades enganadoras (ex: dizer '90% de risco' quando o risco real é 70%).
A.2 Pós-calibração (Platt / Isotonic)	Atenção	Aplicou-se Platt scaling (Brier 0.141) e isotonic regression (Brier 0.126) ao modelo. O melhor Brier pós-calibração é 0.126 vs 0.136 original (variação +7.0%; critério: -10% ou < 0.12). O modelo já está bem calibrado — pouca margem de melhoria, o que é positivo. RESOLVE: probabilidades mal calibradas que distorceriam decisões de corte e provisionamento.
A.3 Estabilidade entre partições (PSI)	Aprovado	O PSI foi calculado entre treino e teste para todas as variáveis. O valor mais alto é 0.083 ('ApplicantIncome'; critério: < 0.1 ok, 0.1-0.2 alerta, > 0.2 falha) — estabilidade elevada. PREVINE: treinar e avaliar em populações diferentes, que daria métricas otimistas e falsas. Serve de baseline para deteção de drift em dados futuros.

B. Explicabilidade e Transparência

Teste	Resultado	Explicação, avaliação e propósito
B.1 Explicação local factual	Aprovado	Geraram-se explicações para 5 casos. 5/5 passaram todos os critérios: factos corretos (score e contribuições batem com os dados), consistência aritmética, e ausência de variáveis protegidas. GARANTE: o direito a explicação (RGPD art. 22) com justificações verdadeiras e não-discriminatórias.

B.2 Estabilidade da explicação	Aprovado	Aplicou-se uma perturbação de +5% ao rendimento em 5 casos e comparou-se a ordem dos fatores. 5/5 mantiveram-se estáveis (desvio ≤ 1 posição). NOTA HONESTA: como as explicações derivam de escalões discretos (não de SHAP contínuo), a estabilidade é elevada por construção — este teste é menos exigente do que num modelo puramente contínuo. PREVINE: explicações erráticas que minariam a confiança do titular.
--------------------------------	----------	---

C. Segurança Avançada (Adversarial)

Teste	Resultado	Explicação, avaliação e propósito
C.1 Ataque de fronteira (gaming)	Aprovado	Partindo de 28 casos reprovados, aplicaram-se alterações plausíveis (≤ 1 desvio-padrão) ao rendimento e montante. 0 (0%) mudaram para aprovado. Abaixo do limiar de risco — o sistema não é facilmente manipulável. PREVINE: candidatos manipularem inputs (ex: inflacionar ligeiramente o rendimento) para forçar aprovação.
C.2 Inversão de modelo	Atenção	Tentou reconstruir-se o rendimento a partir do score. A gama de rendimentos compatíveis com o mesmo score cobre em média 34% da amplitude total (critério: $> 50\%$ = não há reconstrução precisa). O score é demasiado informativo sobre o rendimento. NOTA: relevante sobretudo para exposição futura via API pública; em modo biblioteca é um stress test interno. PREVINE: fuga de dados sensíveis por consulta repetida de scores.
C.3 Robustez a combinações extremas	Aprovado	Geraram-se 20 combinações extremas mas possíveis (rendimento alto sem crédito, baixo com pedido elevado, valores contraditórios). 20/20 foram tratadas sem erro; 0 registos impossíveis foram aprovados (critério: 0). PREVINE: falhas e aprovações indevidas perante combinações raras que o treino não cobriu.

D. Fairness e Viés Estrutural

Teste	Resultado	Explicação, avaliação e propósito
D.1 Correlação indireta com protegidas	Aprovado	Mediu-se a correlação entre cada variável legítima e cada variável protegida. A mais alta é 0.17 entre 'LoanAmount' e 'Education' (critério: ≤ 0.6). Nenhuma variável legítima é um proxy forte de uma protegida. PREVINE: discriminação indireta, em que uma variável 'neutra' carrega informação de uma característica protegida.
D.2 Viés interseccional	Aprovado	Analisaram-se 4 subgrupos combinados (género x estado civil) com ≥ 30 casos. Taxas de aprovação previstas: Female+No 82%, Male+No 85%, Male+Yes 86%, Female+Yes 87%. Rácio 4/5 mínimo entre subgrupos: 0.95 (critério: ≥ 0.8). Sem disparidade interseccional relevante. DETETA: discriminação que só aparece na interseção de atributos (ex: mulheres com dependentes), invisível na análise isolada.

E. Operacionalidade e Deriva

Teste	Resultado	Explicação, avaliação e propósito
E.1 Deriva de conceito (concept drift)	Aprovado	Simulou-se uma mudança de mercado reduzindo em 30% o peso do histórico de crédito. A AUC passou de 0.805 para 0.805 (queda de 0.0 p.p.; critério: ≤ 5 p.p.). O modelo é robusto a esta deriva. PREVINE: degradação silenciosa quando a relação entre variáveis e resultado muda ao longo do tempo.

E.2 Desempenho com partição temporal	Atenção	Comparou-se a AUC com partição aleatória (0.805) vs partição sequencial pela ordem do ficheiro (0.729); diferença 7.6 p.p. (critério: ≤ 3 p.p.). NOTA HONESTA IMPORTANTE: o dataset NÃO tem coluna de data. A ordem do ficheiro não tem significado temporal real, pelo que este teste é um PLACEHOLDER metodológico para quando existirem dados datados — não mede sazonalidade verdadeira. PREPARA: a deteção de sensibilidade temporal em dados reais futuros. RECOMENDAÇÃO: em produção, substituir pela ordenação por carimbo temporal real e reavaliar a sensibilidade à sazonalidade.
--------------------------------------	---------	--

F. Conformidade Regulatória (AI Act)

Teste	Resultado	Explicação, avaliação e propósito
F.1 Checklist de transparência (AI Act art. 13)	Aprovado	Auditou-se a documentação contra os elementos exigidos pelo AI Act para sistemas de alto risco: 7/7 presentes. Todos os elementos obrigatórios estão cobertos: descrição, dados, métricas globais e por subgrupo, limitações, supervisão humana e mitigação de viés. GARANTE: conformidade documental com os requisitos de transparência para sistemas de crédito de alto risco.
F.2 Supervisão humana (human-in-the-loop)	Aprovado	Identificaram-se 1 casos de baixa confiança (probabilidade entre 0.45 e 0.55). 1/1 foram corretamente sinalizados para revisão humana, cada um com um resumo executivo para o analista — sem automatizar a decisão final. DEMONSTRA: a supervisão humana efetiva exigida pelo AI Act para decisões de alto risco em casos incertos.

3. Checklist AI Act — Autoavaliação Técnica

O AI Act classifica sistemas de scoring de crédito como de **alto risco**. A tabela seguinte mapeia os principais requisitos para a forma como o protótipo os cobre tecnicamente. Dois itens estão marcados como não cobertos — a avaliação de conformidade formal e a validação jurídica independente — porque estão, por natureza, fora do alcance de uma autoavaliação do autor. Declará-lo é parte da honestidade deste documento.

Requisito	Ref.	Como o sistema cobre	Estado	Evidência
Sistema de gestão de risco	Art. 9	Pipeline com múltiplas camadas de controlo (guardrails, compliance com veto, monitorização com alarmes PSI/AUC, red team) e testes adversariais documentados.	Coberto	Secção 1 (árvore); Secção 2, categorias Robustez e Segurança
Governança e qualidade dos dados	Art. 10	Tratamento de dados documentado (imputação registada), separação explícita entre variáveis legítimas e protegidas, análise de viés do próprio dataset antes do treino.	Coberto	Secção 2, testes D.1 e D.2; Doc. Validação, secções 2 e 5
Documentação técnica	Art. 11	Documentação técnica de validação gerada automaticamente: arquitetura, dados, métricas, limitações e este documento de sistema.	Coberto	Este documento; CRED ERE_Documentacao_Validacao.pdf
Registo de eventos (logging)	Art. 12	Ledger imutável por hash chain que regista cada decisão com versão do sistema, resultado, alertas e escalonamentos; integridade verificável.	Coberto	Secção 1, etapa 6 (ledger); Secção 2, 'Detecção de adulteração'
Transparência e informação aos utilizadores	Art. 13	Explicações em linguagem natural exatas ao número para cada decisão, com fatores e contribuições; relatório com métricas globais e por subgrupo; limitações declaradas.	Coberto	Secção 1, etapa Explicação; Secção 2, testes B.1 e F.1
Supervisão humana	Art. 14	Módulo human-in-the-loop que escala decisões incertas com resumo executivo; o veto de compliance força revisão humana; nenhum retreino automático.	Coberto	Secção 1, etapa 5 (HITL); Secção 2, teste F.2
Exatidão, robustez e cibersegurança	Art. 15	26 baterias de validação: precisão medida (AUC 0.805, acerto 82%), robustez a dados maliciosos e combinações extremas, ataque de fronteira (gaming), inversão de modelo, deteção de adulteração de registos.	Coberto	Secção 2, categorias Precisão, Robustez, Segurança (C.1-C.3)
Não-discriminação / mitigação de viés	Arts. 9-10 (viés)	Variáveis protegidas excluídas do modelo; fairness guard que deteta proxies; auditoria de disparate impact (regra 4/5) no histórico, nas predições e em subgrupos interseccionais; viés residual documentado e monitorizado.	Coberto	Secção 2, testes D.1, D.2 e Enviesamento
Avaliação de conformidade formal	Arts. 43+	NÃO COBERTO neste protótipo: a avaliação de conformidade formal, marcação CE e registo na base de dados da UE exigem processo legal próprio com organismos notificados — fora do âmbito de uma autoavaliação técnica.	Não coberto	Requer organismo notificado externo

Validação jurídica independente	—	NÃO COBERTO: este documento é uma autoavaliação técnica do autor. A confirmação de conformidade legal requer análise por jurista/DPO qualificado.	Não coberto	Requer jurista / DPO externo
--	---	---	-------------	------------------------------

Cobertura técnica: 8/10 requisitos cobertos pelo protótipo. Os itens não cobertos requerem processos externos (organismos notificados, jurista/DPO) e estão identificados como próximos passos para uma eventual transição a produção.

Documento gerado automaticamente pelo sistema CREDERE. Autoavaliação técnica do autor — não constitui parecer jurídico.