

Plano Final do Sistema e Projeto

CREDERE — Sistema Modular de Scoring de Crédito Explicável
Estado do projeto, arquitetura final e roadmap
Documento elaborado pelo autor e criador do sistema

1. Estado Atual

O CREDERE é um protótipo funcional e testado de um sistema de decisão de crédito, construído módulo a módulo com validação em cada fase. Em números:

Módulos do sistema	16 (+ biblioteca memory-core reutilizável)
Linhas de código	aprox. 12 500 (CREDERE) + 800 (memory-core)
Testes automatizados	240 no CREDERE + 13 na memory-core
Baterias de validação	26 (22 aprovadas, 4 atenção, 0 falhas)
Dataset real integrado	Loan Prediction (614 casos, Kaggle)
Melhor modelo (dados reais)	Regressão logística — AUC 0.805, Gini 0.610, KS 0.495
Achado de fairness	Viés histórico por estado civil (0.63) eliminado das predições ao excluir variáveis protegidas
Documentos gerados	Documentação Técnica de Validação (7 pág.) + Documento de Sistema (8 pág.)

O fluxo completo (guardrail de entrada → scoring/MoE → compliance com veto → guardrail de saída → human-in-the-loop → ledger imutável) está operacional e demonstrável com um comando (python run.py).

2. Arquitetura Final

Os 16 módulos, mapeados às camadas do plano original de 7 camadas. Todas as camadas do plano estão cobertas na sua forma útil e honesta.

Módulo	Camada	Função	Testes
guardrails	4B	Fronteira de entrada/saída: sanidade, anomalias, listas de exclusão, invariantes	19
scoring	2A	Scorecard explicável com reason codes, fairness guard e contrafactuais	23
moe	2B	Especialização por segmento (retail/PME/corporate) com ajuste macro transparente	12
stress	2C	Simulação de trajetórias sob cenários com pressupostos explícitos	10
ml	3	Pipeline ML: logística + XGBoost + ensemble + calibração isotónica + conformal + SHAP	25
fairness	3B	Auditoria de disparate impact (regra 4/5 da EEOC)	8
portfolio	2D	Otimização MILP de portefólio com cutoff dinâmico (PuLP + CBC)	14
casememory	1	Memória semântica de casos decididos (importa a biblioteca memory-core)	11
compliance	4A	Motor neuro-simbólico: regras duras com poder de VETO sobre o estatístico	18
explanation	4C	Explicações em português por templating determinístico + verificação de factos	14
redteam	5A	Agente adversário: dados adulterados, zonas cinzentas, combinações raras	9
monitoring	6B	Evals: AUC, Gini, KS, PSI (drift), confusão por segmento, com alarmes	17
orchestration	7	Pipeline determinístico + ledger hash chain + human-in-the-loop	16
report	—	Relatório PDF de decisão individual	5
data	—	Adaptador de datasets reais + análise + documentação de validação em PDF	17
validation	5/6	Suite de 26 baterias: segurança, privacidade, calibração, fairness, deriva, AI Act	22

A biblioteca **memory-core** (embeddings + armazenamento vetorial, com clientes reais OpenAI/pgvector e fakes determinísticos para teste) foi extraída como pacote independente e é importada pelo módulo casememory — reutilização em vez de reconstrução.

3. Decisões de Engenharia (o que não foi construído, e porquê)

Tão importante como o que o sistema tem é o que deliberadamente não tem. O plano original propunha várias tecnologias que foram recusadas ou substituídas por alternativas mais simples e mais corretas para um sistema regulado. Cada decisão está justificada — esta disciplina é uma característica central do projeto.

Proposta original	Decisão	Justificação
Mamba / Transformer para séries temporais	Recusado	Sem dados sequenciais reais, seria arquitetura-vitrine sobre dados inventados. Substituído por simulação de stress com pressupostos explícitos.
Decomposição de Dantzig-Wolfe	Recusado	O CBC resolve 1000 pedidos em 93 ms — validado empiricamente. A decomposição adicionaria complexidade sem ganho.
Hipocampo artificial / warm-start do solver	Recusado (2x)	Otimizava um não-problema (solver já instantâneo). A intuição de 'memória' foi construída como memória de casos (Camada 1).
Knowledge Graph dinâmico com agente de descoberta	Recusado (3x)	'Descobrir' correlações região-risco em dados sintéticos produziria relações falsas — e é o mecanismo clássico de discriminação geográfica.
LLM como orquestrador com debate de agentes	Recusado	Um pipeline de crédito deve ser determinístico e auditável. Conflitos resolvem-se por hierarquia explícita (compliance veta), não por debate.
Blockchain para logs imutáveis	Substituído	Hash chain SHA-256 dá a mesma garantia de integridade sem a complexidade distribuída. Adulteração detetada e testada.
NeMo Guardrails / Llama Guard	Substituído	São guardrails para LLMs; o CREDERE processa dados estruturados. Construíram-se guardrails de sanidade/anomalia/exclusão adequados.
LLM a gerar justificações de crédito	Substituído	Risco de alucinar números numa comunicação legalmente sensível. Explicações por templating determinístico, exatas; LLM opcional apenas para fluência, sempre re-verificado.
Modelo NLI para verificação de factos	Substituído	Os factos de crédito são números exatos: verificação estruturada (comparação direta) é mais fiável que um classificador probabilístico.
Retreino automático / self-play	Substituído	Auto-modificação sem humano viola a supervisão do AI Act. O sistema deteta, alerta e reporta; a decisão de retreinar é humana.

4. Roadmap — Próximos Passos

O protótipo está completo para demonstração. A transição a produção tem passos identificados, dois deles bloqueantes por natureza (dados de incumprimento reais e validação jurídica).

Item	Prioridade	Descrição
API FastAPI sobre o orquestrador	Alta	Expor o pipeline via REST — a competência mais pedida nas vagas analisadas e o passo natural para o sistema ser consumível. Ativa também os testes de segurança de API (a superfície cyber real).
Champion/challenger (Camada 5B)	Média	Comparação formal de versões de modelos usando as métricas do monitoring — agora trivial de construir sobre o que existe.
Bateria de cenários extremos (Camada 5C)	Média	Estender o stress a uma bateria de cenários macro com relatório de taxa de falha.
Dados reais de incumprimento	Alta (bloqueante para produção)	O dataset atual mede aprovação histórica, não default. Produção exige dados longitudinais de incumprimento para calibrar risco real.
Validação com clientes reais (OpenAI/pgvector)	Baixa	A memory-core tem clientes reais implementados; validar com chaves em ambiente do utilizador.
Validação jurídica (DPO) e conformidade formal	Bloqueante p/ produção	Autoavaliação técnica cobre 8/10 requisitos do AI Act; os 2 restantes exigem jurista e organismos notificados.

5. Como Correr

1. Instalar a memory-core: `cd memory-core && pip install -e .`
2. Instalar o CREDERE: `cd credere && pip install -e ".[dev]" && pip install matplotlib pandas`
3. Demonstração: `python run.py`
4. Testes: `pytest` (240 testes)
5. Documentação de validação: `python gerar_relatorio.py dados/loan_prediction.csv`
6. Documento de sistema: `python gerar_documento_sistema.py dados/loan_prediction.csv`

Documento gerado pelo autor do sistema. Reflete o estado do protótipo à data de geração.